

# Classificação de Issues do Github com Relação a Segurança

1<sup>st</sup> Bruno Gonçalves de Oliveira  
Universidade Federal do Paraná (UFPR)  
Curitiba- PR – Brasil  
bruno.mphx2@gmail.com

2<sup>nd</sup> Diogo Cezar Teixeira Batista  
Universidade Federal do Paraná (UFPR)  
Curitiba- PR – Brasil  
diogocezar@utfpr.br

**Abstract**—As *issues* do GitHub representam grande parte da evolução dos projetos *OpenSource*. Este trabalho propõe uma solução para classificar *issues* que podem ou não estar relacionadas a segurança da informação. As mensagens serão analisadas utilizando as palavras frequentes em textos referentes à segurança. Utiliza-se a técnica de *Bag-of-Words* em conjunto com *TF-IDF* para a criação dos vetores de representação. Na sequência, múltiplos classificadores foram utilizados, entre eles: *svm*, *knn*, *naive\_bayes*, *lda*, *logistic\_regression*, *perceptron*, *tree* e *mlp*. Os resultados obtidos apresentam uma acurácia superior a 80%.

**Index Terms**—Issues, GitHub, Segurança da Informação, Classificadores, Aprendizagem de Máquina

## I. INTRODUÇÃO

O controle, gerenciamento e manutenção de arquivos, especialmente no âmbito do desenvolvimento de *software*, sempre foi um desafio. Problemas recorrentes como: backups não realizados, sobrescritas de arquivos, difícil manutenibilidade de projetos desenvolvidos em equipes, são motivações para a utilização de algum sistema de versionamento de arquivos. [1]

Dentre as várias ferramentas existentes no mercado, como por exemplo: CVS, Subversion, TFS, Mercurial, o Git se destaca por ter sido amplamente utilizado pela comunidade de desenvolvimento, com o advento da popularização dos projetos *OpenSource*. Estes projetos se consolidaram em ferramentas como o GitHub que é uma plataforma para versionamento, gerenciamento e colaboração de projetos, que utiliza o Git como base.

São várias as possibilidades que essas ferramentas proporcionam para versionamento dos projetos, no GitHub, por exemplo, existe uma sessão de *issues* (problemas) na qual, os colaboradores de um projeto *Open Source* podem cadastrar possíveis *bugs*, melhorias, ou novas features para os projetos compartilhados entre os usuários colaboradores.

Na descrição dessas *issues* feita através do preenchimento de um campo de texto, é possível identificar qual é o contexto em que se aplica determinada correção.

Eventualmente, dentre as correções realizadas nestes projetos, são identificados ajustes relacionados a segurança. Essa *issues*, quando consideradas críticas, podem ser analisadas por outros especialistas para uma arguição mais detalhada e um possível aprimoramento.

Mas como identificar quais são os ajustes de um projeto que estão relacionados com segurança? Como separar estes

ajustes para que especialistas possam analisar os códigos? Essas perguntas guiam a motivação para o desenvolvimento deste trabalho.

Propõe-se a criação de uma ferramenta que utilize técnicas de aprendizagem de máquina para a criação de um oráculo classificador que consiga analisar as palavras contidas em uma mensagem de *issue*, e classificar se esta *issue* está ou não relacionada à uma implementação de segurança.

Para criação de uma base de dados de treinamento e testes, duzentas *issues* foram extraídas e classificadas dos projetos *OKHTTP*, *jgit* e *couchbase*.

Para a automatização dos experimentos, foi criado um sistema *orquestrador* no qual é possível definir as instruções para a execução e coleta das evidências de todo o fluxo para os diferentes classificadores, os utilizados neste experimento foram: *svm.LinearSVC*, *KNeighborsClassifier*, *GaussianNB*, *LinearDiscriminantAnalysis*, *LogisticRegression*, *Perceptron*, *DecisionTreeClassifier* e *MLPClassifier*. Para cada um dos testes, anotou-se a acurácia, *f1score*, tempo de execução e sua matriz de confusão.

Por fim, discute-se os resultados obtidos dos experimentos e possíveis trabalhos futuros.

## II. OBTENÇÃO DOS DADOS

Projetos *OpenSource* são, por essência, públicos na Internet, e por este motivo, suas *issues* também estão dispostas de forma pública.

Para a extração dos dados das *issues*, tanto de treinamento quanto de testes, utilizou-se a ferramenta *github-csv-tools*<sup>1</sup> que possibilita a exportação dos dados de um repositório no GitHub, e os salva em um arquivo no formato CSV.

Para a geração da base de testes, foram extraídas as *issues* do projeto *Wildfly*<sup>2</sup>. Já para a base de treinamento utilizou-se *issues* dos projetos: <https://github.com/square/okhttp/>, <https://github.com/eclipse/jgit> e <https://github.com/couchbase>.

Estes dados foram organizados em arquivos no formato CSV que possuem 2 colunas. A primeira coluna indica se a *issue* é um tópico relacionado a segurança ou não, e a segunda coluna representa de fato o texto coletado.

Um exemplo abreviado de cada classe pode ser vista no Código 1.

<sup>1</sup><https://github.com/gavinr/github-csv-tools>

<sup>2</sup><https://github.com/wildfly/wildfly>

```

1 security.PushObserver can be used to push
  serverinitiated HTTP/2 requests into an
  OkResponseCache...
2 not,Handle LOCKED in conversions.Motivation...

```

Código 1. CSV Exemplo com Base de Dados

Os dados de treinamento possuem 199 entradas, enquanto que para a base de teste foram utilizadas 211 entradas.

### III. PRÉ-PROCESSAMENTO

Após a obtenção dos dados, é importante a realização de algumas etapas de pré-processamento do texto, estes tratamentos procuram maximizar a representatividade das *issues* de acordo com o seu significado.

Para isso, é necessário remover palavras que não representam o contexto das frases. Com esse objetivo, aplicou-se técnicas para cada uma das frases das *issues* da base de treinamento e testes.

As regras aplicadas foram:

- 1) Transformar todo texto em minúsculo;
- 2) Ignorar pontuações;
- 3) Corrigir palavras com ortografia incorreta;
- 4) Remover as chamadas *stop words* que não acrescentam informação aos textos, por exemplo: *of, a, in, on*.

Para a aplicação das regras criou-se uma função de preparação do *dataset* que foi aplicada tanto na base de testes quanto na base de treinamento.

### IV. EXTRAÇÃO DE CARACTERÍSTICAS

Para a extração de características, utiliza-se uma técnica conhecida como *Bag-of-Words*. Nesta técnica, as sentenças são representadas através da identificação de suas palavras e a quantidade em que aparecem no texto. Por exemplo, considerando o seguinte texto, escrito por *Charles Dickens*:

It was the best of times,  
It was the worst of times,  
It was the age of wisdom,  
It was the age of foolishness.

Considerando palavras únicas, neste caso, teríamos um vocabulário com 10 palavras: [it, was, the, best, of, times, worst, age, wisdom, foolishness]

Na sequência deve-se criar os vetores que representam a quantidade de aparições de uma palavra no texto. Por exemplo, no documento "It was the age of wisdom" pode-se representar através de um vetor dado por: [1, 1, 1, 0, 1, 0, 0, 1, 1, 0]. Se novas frases, com palavras fora do vocabulário definido forem adicionadas, então essas serão descartadas.

Com os vetores de palavras formados com a identificação e a quantidade, é possível aplicar a técnica de *TF-IDF* (*term frequency-inverse document frequency*). Nesta abordagem, valoriza-se o quão importante uma palavra é ao documento. O valor de *TF-IDF* aumenta proporcionalmente conforme o número de vezes a palavra aparece no texto e é compensado pelo número de textos na base de dados, ajustando o número da frequência das palavras.

Basicamente para cada uma das *issues* já sanitizadas aplica-se uma contagem das palavras mais relevantes para o problema em questão. Essas palavras foram obtidas a partir de uma contagem das palavras que mais apareciam nas *issues* que eram relacionadas à segurança.

Obteve-se as seguintes palavras: ['security', 'secure', 'vulnerable', 'leak', 'exception', 'crash', 'malicious', 'sensitive', 'user', 'authentication', 'protect', 'vulnerability', 'authenticator', 'auth', 'npe']

Após a aplicação destas técnicas, obtém-se 4 vetores que serão utilizados nas próximas fases do experimento. São eles: (x\_train, y\_train, x\_test, y\_test)

### V. ORQUESTADOR DOS EXPERIMENTOS

Essencialmente em problemas que podem envolver diferentes classificadores, é bastante comum a realização dos experimentos em diferentes abordagens, utilizando classificadores diferentes, e para cada um dos classificadores, parâmetros diferentes.

Com o intuito de automatizar o processo de variação entre os experimentos, desenvolveu-se um sistema orquestrador de classificadores.

Este sistema utiliza um arquivo no formato *JSON* para definir 2 principais blocos: configurações e experimentos.

No bloco de configurações, é possível definir quais serão os arquivos de entrada e saída para a realização dos experimentos. Já no bloco de experimentos define-se um *array* com todos os experimentos a serem realizados.

Um exemplo do arquivo de orquestração pode ser visto no Código 2.

```

1 {
2   "configs": {
3     "train": "data/train.csv",
4     "test": "data/test.csv",
5     "result_classifiers": "results/classifiers /
      tabulation_{timestamp}.csv",
6     "result_conf_mat": "results/conf_mat/"
7   },
8   "experiments": [
9     {
10      "classifier": "svm",
11      "parameters": {}
12    },
13    {
14      "classifier": "knn",
15      "parameters": {
16        "n_neighbors": 7
17      }
18    },
19    ...
20  ]
21 }

```

Código 2. JSON do Orquestrador

Para cada uma das ocorrências no vetor de experimentos, o programa desenvolvido utiliza implementações do *framework* <sup>3</sup>*scikit-learn* para o treinamento do classificador. Utilizando como fonte de dados, as entradas já tratados anteriormente (x\_train, y\_train, x\_test, y\_test). Os resultados são armazenados automaticamente em um arquivo no formato CSV que tabula os resultados obtidos em cada um dos experimentos. Os

<sup>3</sup><https://scikit-learn.org/>

campos salvos são: *Classifier*, *F1Score*, *Accuracy* e *Time (s)*. Além disso, para cada execução são armazenadas as matrizes de confusão como imagens e também como arquivos CSV.

## VI. RESULTADOS OBTIDOS

O orquestrador dos experimentos foi configurado para executar os experimentos com os classificadores: *svm.LinearSVC*, *KNeighborsClassifier*, *GaussianNB*, *LinearDiscriminantAnalysis*, *LogisticRegression*, *Perceptron*, *DecisionTreeClassifier* e *MLPClassifier*.

Os parâmetros utilizados foram os default em cada um dos classificadores. Com a execução do *KNeighborsClassifier* em que se testou com *n\_neighbors: 7* e *LogisticRegression* que se utilizou *solver: lbfgs*.

Os resultados obtidos estão dispostos na Tabela I.

Classifier	Accuracy	F1Score	Time (s)
LinearDiscriminantAnalysis	0.867	0.865	0.183
LogisticRegression	0.867	0.865	0.191
DecisionTreeClassifier	0.867	0.865	0.193
MLPClassifier	0.867	0.865	0.302
svm.LinearSVC	0.867	0.865	1.903
Perceptron	0.862	0.861	0.17
KNeighborsClassifier	0.533	0.696	0.229
GaussianNB	0.471	0.307	0.192

TABLE I  
RESULTADOS DOS EXPERIMENTOS

As matrizes de confusão dos classificadores: *DecisionTreeClassifier*, *GaussianNB*, *KNeighborsClassifier* e *LinearDiscriminantAnalysis* estão dispostas na Figura 1. Já para os classificadores: *svm.LinearSVC*, *LogisticRegression*, *MLPClassifier* e *Perceptron* as representações estão dispostas na Figura 2.




Fig. 1. Matrizes de Confusão 1

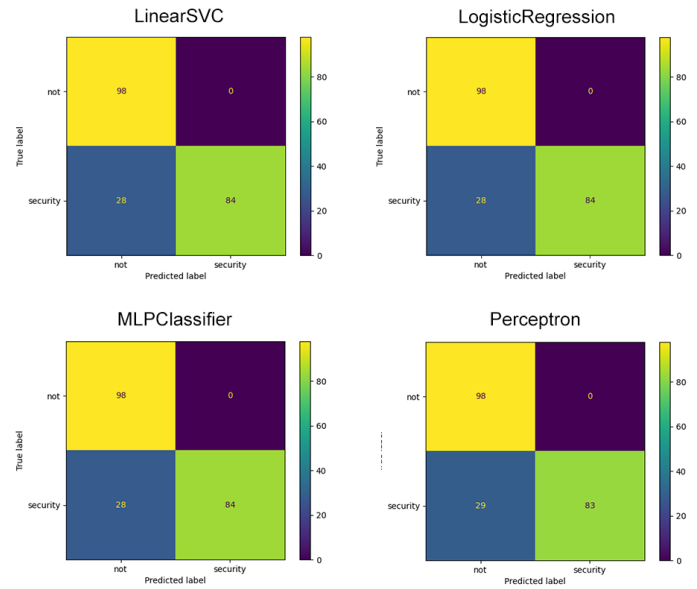


Fig. 2. Matrizes de Confusão 2

## VII. CONCLUSÃO

## VIII. TRABALHOS FUTUROS

Para aumentar a base de treinamento, pode-se desenvolver um programa que extrai automaticamente informações de issues de repositórios do GitHub marcados com um *label* que contenha informações relacionadas a segurança. O GitHub, oferece uma API que possibilita a extração de informações no formato JSON, o que facilitaria este processo. É possível notar que em alguns projetos, existem issues pré-classificadas com labels, como é o exemplo do repositório do projeto Angular, disponível em: <https://github.com/angular/angular/labels?q=sec>.

Ainda é possível evoluir a ideia do classificador para a criação de uma API que retorne se uma mensagem é ou não referente a segurança, que poderia ser utilizada em outros contextos.

## IX. CÓDIGO FONTE

O código fonte dos experimentos pode ser acessado em: <https://github.com/bmphx2/aprendizagem-de-maquina>

## REFERENCES

- [1] S. Chacon and B. Straub, *Pro Git*. Apress, 2020.